PROYECTO 4 · FASE 1 · ANÁLISIS Y JUSTIFICACIÓN

# NYC Mobility Pulse

## Dashboard táctico de movilidad urbana con datos abiertos de NYC Yellow Taxi Trip Records

Documento de justificación de las actividades de análisis: audiencia, objetivos, preprocesamiento de datos, selección del tipo de dashboard y arquitectura de la solución.


MÓDULO
Visualización de datos

DOCENTE
Jessica Carmin Mendiola Fuentes

EQUIPO
Mobility Pulse

INTEGRANTES
Javier Rodríguez Rodríguez
Diego Alonso López Ballesta


TEMA
Transporte, ciudades inteligentes y sostenibilidad urbana

DATASET
NYC TLC Yellow Taxi Trip Records

FUENTE
NYC Taxi & Limousine Commission

FECHA
31/10/2026

## Contenido


01 Resumen ejecutivo 3

02 Contexto y definición del problema 3

03 Análisis de la audiencia 4

04 Objetivos del dashboard 5

05 Selección del tipo de dashboard 6

06 Dataset y variables 7

07 Preprocesamiento de datos 8

08 Indicadores y visualizaciones 11

09 Arquitectura de la solución 13

10 Hallazgos y lectura del tablero 14

11 Limitaciones y sesgos 15

12 Conclusiones 16

13 Referencias 16


> **Repositorio y demo.** El código, el pipeline reproducible y el dashboard se publican en GitHub Pages. La muestra de trabajo contiene 4.000.000 viajes (500,000 por año) y el reporte de calidad conserva los totales exactos de los archivos fuente.

## 01 · Resumen ejecutivo

> Nueva York produce cientos de millones de viajes en taxi al año. Convertir ese volumen en decisiones requiere algo más que un tablero vistoso: exige definir quién lo va a leer, qué decisión habilita y cómo se limpian los datos antes de graficarlos. Este documento justifica esas decisiones.

El proyecto **NYC Mobility Pulse** construye un dashboard táctico sobre los registros de viajes de taxi amarillo publicados por la NYC Taxi & Limousine Commission (TLC). El tablero responde a tres preguntas: cuándo se mueve la ciudad, dónde se concentra la demanda y cuánto cuesta y qué tan eficiente es cada viaje. Para ello se procesaron 86,9 GB de archivos CSV correspondientes a ocho años (2015, 2017, 2018, 2019, 2020, 2021, 2022 y 2025), se aplicó un esquema de limpieza documentado y se extrajo una muestra reproducible de 500,000 viajes por año.

La solución combina una capa de datos reproducible (Python + DuckDB + Parquet), una capa analítica (agregados exportados a JSON) y una capa de presentación (React, Recharts y Leaflet) publicada como sitio estático en GitHub Pages. El resultado es un tablero que un gerente de operaciones puede leer en menos de un minuto y que un analista puede auditar hasta el registro original.

## 02 · Contexto y definición del problema

El taxi amarillo es uno de los termómetros más finos de la actividad urbana de Nueva York. Sus viajes registran hora, coordenadas o zona, distancia, duración, tarifa, propina y método de pago. Esa combinación permite observar fenómenos que otras fuentes no capturan con el mismo detalle: la caída de la demanda durante la pandemia, la recuperación del ocio nocturno, la presión de la congestión en horas pico o la dependencia del efectivo en determinados corredores.

Sin embargo, el dataset original no es un tablero: son archivos anuales de varios gigabytes, con esquemas que cambian entre años, fechas en formatos distintos, importes con separadores de miles y registros corruptos. Un analista sin un proceso definido tarda horas en llegar a la primera respuesta y corre el riesgo de comparar años que no son comparables.

**Problema que resuelve el dashboard:** reducir el tiempo y la ambigüedad para responder preguntas de capacidad, cobertura y precio de la movilidad en taxi, con una lectura visual común para perfiles técnicos y no técnicos, y con un pipeline auditable que garantice que las cifras comparadas provienen de criterios homogéneos.

El alcance se limita a los viajes en *yellow taxi*. No incluye Uber, Lyft, taxis verdes ni transporte público. Tampoco pretende explicar la demanda con variables externas (clima, eventos, precio del combustible): el objetivo es descriptivo y de seguimiento, no causal.

## 03 · Análisis de la audiencia

El dashboard tiene una audiencia primaria y tres secundarias. La diferencia entre ellas no es el nivel de interés, sino el **nivel de detalle** y la **frecuencia de uso**. El diseño prioriza la audiencia primaria y deja capas de exploración para las demás.

| Perfil | Decisiones que toma | Nivel de detalle | Frecuencia |
|---|---|---|---|
| **Gerencia de operaciones y flota**<br>Audiencia primaria | Asignar turnos y unidades, anticipar picos, decidir dónde posicionar flota y cómo ajustar tarifas o incentivos. | Alto: año, mes, día, hora y zona. Necesita comparar contra el año anterior y detectar desvíos. | Semanal / mensual |
| **Analistas de movilidad**<br>Audiencia técnica | Validar hipótesis, construir modelos de demanda, auditar la calidad de los datos y preparar reportes. | Muy alto: acceso a la muestra, diccionario de variables, reglas de limpieza y base DuckDB. | Bajo demanda |
| **Planificación urbana**<br>Audiencia institucional | Identificar corredores congestionados, zonas con baja cobertura y oportunidades de política pública. | Medio: mapas por zona y borough, rutas frecuentes, duración y velocidad. | Mensual / trimestral |
| **Dirección y comunicación**<br>Audiencia ejecutiva | Entender la tendencia general, comunicar resultados y decidir si se requiere una acción. | Bajo: KPIs, serie histórica y tres o cuatro hallazgos claros. | Mensual |

Tabla 1. Perfiles de audiencia, decisiones y nivel de detalle requerido.

### Implicaciones de diseño

- **Jerarquía visual:** los KPIs y la serie mensual aparecen primero; el detalle por zona, ruta y distribución queda después. Un lector ejecutivo puede detenerse en la primera pantalla sin perderse.
- **Filtro de año global:** todas las visualizaciones responden al mismo selector para evitar comparaciones accidentales entre periodos.
- **Comparación explícita:** la serie mensual muestra el año previo disponible, no un promedio ciego, porque la pregunta operativa es “¿estamos por encima o por debajo del año pasado?”.
- **Exploración progresiva:** el mapa permite hacer clic en una zona y ver su detalle; la tabla de rutas y el boxplot añaden profundidad sin saturar la primera lectura.
- **Transparencia:** la sección de metodología declara la muestra, las reglas de limpieza y el porcentaje de registros válidos. Un analista puede reconstruir el resultado con los scripts del repositorio.

## 04 · Objetivos del dashboard

### Objetivo general

Diseñar e implementar un dashboard táctico que permita **monitorear y comparar la demanda, la geografía y la economía de los viajes en taxi amarillo de Nueva York** entre 2015 y 2025, con una muestra reproducible y un proceso de limpieza documentado, para apoyar decisiones de capacidad, posicionamiento y precio.

### Objetivos específicos

1. Identificar los patrones temporales de la demanda (mes, día de la semana y hora) y detectar los periodos de mayor y menor actividad.
2. Localizar las zonas y boroughs con mayor concentración de viajes, así como los corredores origen–destino más frecuentes.
3. Comparar la estructura económica del viaje (tarifa, tarifa por milla, propina y método de pago) entre años.
4. Evaluar la eficiencia del viaje (duración, velocidad y distancia) y contrastar hora pico contra valle y fin de semana.
5. Documentar y automatizar el preprocesamiento para que los resultados sean reproducibles y auditables.

### Preguntas que el tablero debe responder

**Demanda**
¿Qué mes, día y hora concentran más viajes? ¿Cómo cambió la demanda respecto al año anterior? ¿Dónde se produjo la caída de 2020?

**Territorio**
¿Qué zonas originan más viajes? ¿Qué boroughs concentran la actividad? ¿Qué rutas se repiten más y cuánto duran?

**Economía**
¿Cuánto cuesta un viaje típico? ¿Cuánto se paga por milla? ¿Qué método de pago deja más propina?

**Eficiencia**
¿Cuánto tarda un viaje en hora pico frente a un valle? ¿La tarifa crece linealmente con la distancia? ¿Qué velocidad media tiene la ciudad?

## 05 · Selección del tipo de dashboard

La literatura distingue tres tipos de dashboard según su horizonte temporal y su audiencia. La elección no es estética: determina la frecuencia de actualización, el nivel de agregación y el tipo de decisión que habilita.

| Tipo | Propósito | Horizonte / actualización | Encaje con el proyecto |
|---|---|---|---|
| **Operativo** | Monitorear métricas en tiempo real para decisiones del día. | Minutos u horas; datos en vivo. | Parcial: el dataset es histórico y se publica por lotes; no hay feed en vivo. |
| **Táctico** | Analizar el rendimiento a medio plazo y apoyar decisiones gerenciales. | Semanas o meses; comparación entre periodos. | **Alto:** años completos, comparación interanual, zonas y tarifas. |
| **Estratégico** | Visión de largo plazo para la alta dirección. | Años; pocos indicadores muy agregados. | Parcial: el tablero tiene detalle operativo que excede una vista estratégica. |

Tabla 2. Comparación de tipos de dashboard y su encaje con el proyecto.

**Decisión: dashboard táctico con capacidad de exploración operativa.** La unidad de análisis es el año y el mes; la comparación principal es interanual; la audiencia primaria es gerencia de operaciones. El tablero no pretende reemplazar un sistema de despacho en tiempo real (operativo), pero sí permite bajar al detalle de hora y zona cuando se necesita investigar un desvío. Se descarta el estratégico puro porque la riqueza del dataset —263 zonas, 168 franjas horarias, rutas— se perdería en un solo indicador agregado.

Esta elección también responde a la naturaleza de GitHub Pages: al ser un sitio estático, no hay consultas en vivo ni actualización minuto a minuto. Un dashboard operativo exigiría un backend y una base de datos expuesta; el enfoque táctico es coherente con la arquitectura elegida y con el uso real del dataset, que la TLC publica con rezago.

## 06 · Dataset y variables

El conjunto proviene del portal de datos abiertos de la TLC. Cada archivo anual contiene los viajes de taxi amarillo con columnas que evolucionaron con los años: 2015 usa `pickup_datetime` y coordenadas; desde 2016 se incorporan `PULocationID` y `DOLocationID`; en años recientes se añaden recargos de congestión y tarifas aeroportuarias.

| Archivo | Tamaño | Registros fuente | Válidos | Muestra |
|---|---|---|---|---|
| 2015 | 26,89 GB | 146.087.462 | 142.426.581 (97,5%) | 500.000 |
| 2017 | 14,62 GB | 113.496.874 | 112.145.097 (98,8%) | 500.000 |
| 2018 | 14,47 GB | 112.234.626 | 110.766.890 (98,7%) | 500.000 |
| 2019 | 11,22 GB | 84.399.019 | 82.975.749 (98,3%) | 500.000 |
| 2020 | 3,32 GB | 24.648.499 | 24.066.597 (97,6%) | 500.000 |
| 2021 | 4,11 GB | 30.904.072 | 30.152.291 (97,6%) | 500.000 |
| 2022 | 5,45 GB | 39.656.098 | 38.637.317 (97,4%) | 500.000 |
| 2025 | 6,79 GB | 48.048.582 | 44.429.160 (92,5%) | 500.000 |

Tabla 3. Volumen por año, registros válidos tras la limpieza y muestra extraída.

Los años 2016, 2023 y 2024 no forman parte del conjunto entregado. El tablero los declara como huecos y no interpola valores: una línea que une 2022 con 2025 sin advertirlo sería una lectura engañosa.

### Variables relevantes

| Variable | Tipo | Significado y uso |
|---|---|---|
| `pickup_datetime` / `tpep_pickup_datetime` | fecha-hora | Inicio del viaje. Base para mes, día, hora y duración. |
| `dropoff_datetime` / `tpep_dropoff_datetime` | fecha-hora | Fin del viaje. Permite calcular duración y detectar registros inválidos. |
| `trip_distance` | decimal (mi) | Distancia recorrida. Se usa para tarifa por milla y velocidad. |
| `PULocationID`, `DOLocationID` | entero | Zona TLC de origen y destino (1–265). Base del mapa y las rutas. |
| `pickup_latitude`, `pickup_longitude` | decimal | Coordenadas disponibles en 2015; se usan para asignar zona por point-in-polygon. |
| `fare_amount` | decimal (USD) | Tarifa base antes de impuestos y propina. |
| `tip_amount` | decimal (USD) | Propina registrada; solo confiable en pagos electrónicos. |
| `total_amount` | decimal (USD) | Monto total cobrado. Se usa para el ingreso agregado. |
| `payment_type` | categórico | 1 tarjeta, 2 efectivo, 3 sin cargo, 4 disputa, 5 desconocido, 6 anulado. |
| `passenger_count` | entero | Pasajeros declarados; se usa como control de calidad. |

Tabla 4. Diccionario de variables utilizadas en el dashboard.

## 07 · Preprocesamiento de datos

El preprocesamiento se diseñó como un pipeline de cuatro etapas reproducible. Cada decisión se implementó en código y se registra en el reporte de calidad; no se hicieron ajustes manuales sobre los archivos.

### 7.1 Identificación y entendimiento

Primero se inspeccionaron los encabezados y una muestra de filas de cada archivo. Se identificaron cuatro problemas estructurales:

- **Esquemas distintos:** 2015 usa nombres en minúscula y coordenadas; 2016+ usa `VendorID`, `tpep_*` y `PULocationID`. Se construyó un esquema común con `COALESCE` y detección de columnas por archivo.
- **Formatos de fecha heterogéneos:** `2015 Aug 18 08:31:49 AM` y `01/01/2019 12:46:40 AM`. Se probaron formatos en cascada y se validó que la fecha cayera dentro del año del archivo.
- **Números con separador de miles:** aparecen importes como `"-1,242.3"` entre comillas. Se eliminó la coma antes de convertir a `DOUBLE` con `TRY_CAST` para no romper el pipeline.
- **Registros corruptos:** el archivo de 2018 contiene fechas con año 2084 y viajes con duración negativa o nula. Se descartan por regla, no se corrigen a mano.

### 7.2 Limpieza aplicada

| Regla | Criterio | Justificación |
|---|---|---|
| Fecha válida | Pickup y dropoff parseables; pickup dentro del año del archivo. | Evita mezclar años y descarta el año corrupto 2084. |
| Duración | Entre 1 minuto y 6 horas. | Elimina viajes de 0 s y registros con duraciones imposibles. |
| Distancia | Entre 0.1 y 100 millas. | Descarta distancias nulas y valores absurdos para la ciudad. |
| Importes | Tarifa entre 0 y 500 USD; total entre 0 y 1,500 USD; propina entre 0 y 300 USD. | Excluye reembolsos, disputas y errores de captura sin recortar viajes normales. |
| Pasajeros | Entre 0 y 8 cuando el dato existe. | El campo es opcional; se conserva el nulo, se descarta el imposible. |
| Zonas | `PULocationID` y `DOLocationID` entre 1 y 265. | El catálogo TLC tiene 263 zonas; los códigos fuera de rango son errores. |
| Coordenadas | Dentro de la caja NYC (lat 40.4–41.1, lon −74.3 a −73.6). | Solo aplica a 2015; descarta puntos fuera de la ciudad. |

Tabla 5. Reglas de limpieza y su justificación.

### 7.3 Manejo de valores atípicos

Se adoptó un criterio de **descarte** y no de imputación. La razón es conceptual: el dashboard describe viajes reales; reemplazar una tarifa extrema por la media inventaría un viaje que no ocurrió y distorsionaría la distribución. Los umbrales se fijaron con conocimiento del dominio (tarifas y distancias plausibles en NYC) y se validaron contra la distribución observada.

Para la visualización de la dispersión se aplicó un recorte adicional (distancia 0.2–25 mi, tarifa 2–90 USD, duración 2–120 min) para que la nube de puntos sea legible. Ese recorte es **solo visual**: los KPIs y las distribuciones se calculan con la muestra completa ya limpia.

> **Resultado de la limpieza.** De 599.475.232 registros fuente, quedaron 585.599.682 válidos (97,7%). Las principales causas de descarte fueron duraciones fuera de rango, distancias nulas o extremas y coordenadas fuera de NYC en 2015.

### 7.4 Integración de datos

La integración se resolvió con DuckDB, que permite leer CSV completos sin cargarlos en memoria y escribir Parquet columnar. El flujo es:

1. **Extracción y normalización:** cada CSV se lee como texto, se normalizan nombres y tipos, y se aplican las reglas de limpieza.
2. **Muestreo:** se toma una muestra aleatoria de 500,000 viajes por año con *reservoir sampling* y semilla 42. La muestra es reproducible y conserva la estructura del año.
3. **Persistencia:** las muestras se guardan en `data/samples/*.parquet` y se materializa la base `data/taxi_mobility.duckdb` con las tablas `trips_sample`, `zones` y `quality`.
4. **Enriquecimiento geográfico:** para 2015 se hace un join espacial punto-en-polígono contra el shapefile oficial de zonas TLC, porque ese año no trae `PULocationID`.
5. **Agregación:** se calculan KPIs, series mensuales, matriz hora × día, métricas por zona y borough, histogramas, boxplot, dispersión y rutas. El resultado se exporta a `public/data/dashboard.json`.

Esta separación permite que el sitio estático cargue en segundos y que cualquier persona pueda reconstruir las cifras ejecutando los cuatro scripts del directorio `etl/`.

### 7.5 Reporte de calidad

El pipeline genera `data/quality_report.json` con el total de registros, los válidos, los descartes por regla y el tiempo de procesamiento por año. Ese reporte alimenta la tabla 3 y la sección de metodología del dashboard. La muestra final contiene 4.000.000 viajes.

## 08 · Indicadores y visualizaciones

Cada visualización responde a una pregunta y habilita una decisión. No se incluyeron gráficos “decorativos”: si un elemento no cambia una lectura, se retiró.

| Indicador / visual | Definición | Pregunta que responde |
|---|---|---|
| Viajes analizados | Conteo de viajes de la muestra del periodo. | ¿Cuál es el volumen de actividad? |
| Ingreso total | Suma de `total_amount`. | ¿Cuánto dinero mueve la operación? |
| Tarifa promedio | Media de `fare_amount`. | ¿Cuánto cuesta un viaje típico? |
| Tarifa por milla | `Σ fare / Σ distancia` | ¿Cuánto se cobra por unidad de distancia? |
| Propina promedio | `100 × Σ tip / Σ fare` | ¿Qué tan generoso es el pasajero? |
| Velocidad promedio | `distancia / (duración / 60)`, filtrada 1–60 mph. | ¿Qué tan congestionada está la ciudad? |
| Serie mensual | Viajes por mes; barras del año y línea del año previo. | ¿Cómo evoluciona la demanda y cómo se compara con el año anterior? |
| Mapa de calor | Matriz 7 días × 24 horas. | ¿Cuándo se concentra la demanda dentro de la semana? |
| Coropleta de zonas | Viajes por zona TLC; métricas de origen, destino y tarifa. | ¿Dónde se origina y dónde termina la demanda? |
| Ranking de zonas | Top 10 por viajes de origen y participación. | ¿Qué zonas son críticas para la operación? |
| Histogramas | Distribución de tarifa y distancia por rangos. | ¿Cuál es la forma de la distribución y dónde está la masa? |
| Método de pago | Participación y propina media por tipo. | ¿Qué canal de pago deja más propina? |
| Boxplot | Cuartiles de duración por franja: pico, valle, fin de semana, madrugada. | ¿Cuánto penaliza la congestión al viaje? |
| Dispersión | Distancia vs. tarifa; color por método de pago; correlación. | ¿La tarifa crece con la distancia? ¿Hay valores atípicos? |
| Rutas | Top 10 pares origen–destino. | ¿Qué corredores requieren capacidad? |

Tabla 6. Indicadores, definición y pregunta de decisión.

### Criterios de selección visual

- **Línea y barras para el tiempo:** la comparación entre años se lee mejor con barras (año seleccionado) y una línea de referencia (año previo) que con dos áreas superpuestas.
- **Mapa de calor para dos dimensiones categóricas:** 168 celdas permiten ver de un golpe el ritmo semanal; una tabla de 168 filas no.
- **Coropleta para geografía:** la zona es la unidad operativa real; un mapa de puntos con 500,000 viajes sería ilegible y pesado.
- **Boxplot para comparar distribuciones:** la media de duración esconde la dispersión; los cuartiles muestran si el pico afecta a todos los viajes o solo a la cola.
- **Dispersión con muestra:** se grafican 320 puntos por año para mantener el rendimiento y evitar sobrexplotación visual.

## 09 · Arquitectura de la solución

La solución se organiza en tres capas. La primera es reproducible y vive en Python; la segunda es un contrato de datos en JSON; la tercera es la interfaz React publicada como sitio estático.

| Capa | Tecnología | Responsabilidad |
|---|---|---|
| Datos | Python 3.10, DuckDB, Parquet, Shapely | Lectura de CSV, limpieza, muestreo, join espacial y base de datos. |
| Agregados | SQL + JSON | KPIs, series, matriz horaria, zonas, histogramas, boxplot, dispersión y rutas. |
| Presentación | React 19, TypeScript, Vite, Recharts, Leaflet | Interfaz, filtros, tooltips, mapa interactivo y diseño responsive. |
| Despliegue | GitHub Actions + GitHub Pages | Build automático y publicación del sitio estático. |

Tabla 7. Capas de la arquitectura.

La base de datos elegida es **DuckDB**, una base analítica embebida. Se prefirió sobre PostgreSQL o MongoDB porque el proyecto es analítico, de solo lectura y de un solo equipo: DuckDB no requiere servidor, lee CSV y Parquet de forma nativa, y permite reproducir todo el pipeline en una laptop. La base resultante contiene 4 millones de viajes y el catálogo de zonas, y puede consultarse con SQL estándar.

El dashboard no consulta la base en vivo porque GitHub Pages no ejecuta backend. En su lugar, el paso 04 exporta agregados a `public/data/dashboard.json`. Es una decisión deliberada de arquitectura: reduce el tiempo de carga, evita exponer credenciales y mantiene el sitio gratuito y público. El costo es que los datos no se actualizan solos; para actualizarlos se vuelve a ejecutar el pipeline y se hace commit del JSON.

## 10 · Hallazgos y lectura del tablero

Los siguientes hallazgos se obtuvieron con la muestra y se actualizan automáticamente al cambiar el año en el dashboard.

→ **La ciudad se concentra:** Upper East Side South (Manhattan) origina el 4,4% de los viajes de la muestra; Manhattan concentra el 90,6% del total por borough.

→ **El pico semanal:** la franja más activa es el jueves a las 18:00, con 40.997 viajes en la muestra histórica.

→ **Economía del viaje:** la tarifa media es de $14,11 y la tarifa por milla de $4,50. La velocidad media es de 11,7 mph.

→ **Propina y canal de pago:** la propina declarada promedia 15,8%; en tarjeta es 22,2% frente a 0,0% en efectivo, lo que confirma el sesgo de registro del efectivo.

→ **Congestión:** la mediana de duración en hora pico es 11,8 min frente a 11,9 min en valle, un 0,8% menos. El boxplot muestra si el efecto se distribuye en toda la población o solo en la cola.

→ **El shock de 2020:** los registros de la fuente cayeron 70,8% respecto a 2019 (de 84.399.019 a 24.648.499 viajes). La serie mensual permite ubicar el inicio del desplome y la velocidad de recuperación posterior.




Figura 1. Vista general del dashboard: KPIs, serie mensual y lecturas rápidas.

## 11 · Limitaciones y sesgos

- **Muestra, no censo.** El tablero usa 500,000 viajes por año. Las proporciones son representativas, pero los conteos absolutos no deben compararse con las cifras oficiales de la TLC. El reporte de calidad incluye los totales fuente para contextualizar.
- **Propina subestimada en efectivo.** El campo `tip_amount` solo es confiable en pagos electrónicos; en efectivo suele registrarse como cero. Por eso el indicador se lee como “propina declarada”, no como propina real.
- **Cobertura geográfica de 2015.** Ese año no trae `PULocationID`; la zona se asigna por point-in-polygon. Los viajes cuyos puntos caen fuera de los polígonos quedan sin zona y no entran en el mapa, aunque sí en los KPIs generales.
- **Años faltantes.** 2016, 2023 y 2024 no están en el conjunto. Las comparaciones interanuales usan el año previo disponible y el tablero lo indica explícitamente.
- **Marzo de 2018 duplicado en la fuente.** El archivo original de la TLC para ese mes contiene unos 18.9 millones de filas frente a 8–9 millones en los demás meses. El bloque no es un duplicado exacto, así que se conserva y se señala en la serie mensual en lugar de eliminarlo con un criterio arbitrario.
- **Sesgo de servicio.** El taxi amarillo tiene una distribución geográfica distinta a la de otras modalidades. Los hallazgos describen ese servicio, no toda la movilidad de Nueva York.
- **Datos estáticos.** GitHub Pages no permite consultas en vivo; la actualización requiere volver a ejecutar el pipeline.

## 12 · Conclusiones

La Fase 1 permitió convertir un conjunto de archivos masivos y heterogéneos en una base de decisión coherente. El análisis de audiencia definió qué mostrar y en qué orden; los objetivos acotaron el alcance; el preprocesamiento garantizó que los años fueran comparables; y la elección de un dashboard táctico alineó la interfaz con el uso real del dataset y con las restricciones de un sitio estático.

El resultado es **NYC Mobility Pulse**: un tablero que permite pasar de la tendencia general a la zona específica en pocos clics, con un pipeline reproducible y una declaración explícita de sus límites. La siguiente fase puede profundizar en modelos de demanda, actualización automática de datos o integración con otras fuentes de movilidad.

Javier Rodríguez Rodríguez

Diego Alonso López Ballesta

## 13 · Referencias

1. NYC Taxi & Limousine Commission. *TLC Trip Record Data*. https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page
2. NYC TLC. *Taxi Zone Lookup* y *Taxi Zones shapefile*. https://d37ci6vzurychx.cloudfront.net/misc/taxi_zone_lookup.csv
3. DuckDB Foundation. *DuckDB Documentation*. https://duckdb.org/docs/
4. React. *React Documentation*. https://react.dev/
5. Recharts. *Recharts Documentation*. https://recharts.org/
6. Leaflet. *Leaflet Documentation*. https://leafletjs.com/
7. GitHub. *GitHub Pages Documentation*. https://docs.github.com/pages

Documento generado a partir de `docs/justificacion.template.html` y de los resultados del pipeline (`data/quality_report.json` y `public/data/dashboard.json`). Equipo Mobility Pulse · Módulo de Visualización de datos · 31/10/2026.